

# Pontificia Universidad Católica del Perú

Facultad de Ciencias e Ingeniería



Deep Learning (1INF52)

Informe de Proyecto

Cántaro Márquez, Patricia Natividad	20210907
Nicho Manrique, Saymon Estefano	20211866
Zegarra Barrenechea, Carlos Eduardo	20216177

January 27, 2025

# Contents

<b>1</b>	<b>Introducción</b>	<b>2</b>
<b>2</b>	<b>Planteamiento del Problema</b>	<b>3</b>
<b>3</b>	<b>Estado del Arte</b>	<b>4</b>
<b>4</b>	<b>Marco Teórico</b>	<b>5</b>
4.1	Redes Neuronales Convolucionales . . . . .	5
4.2	YOLO . . . . .	5
4.3	Transfer Learning . . . . .	6

# 1 Introducción

Los incendios forestales representan una amenaza para el medio ambiente y la salud pública. En la actualidad, su impacto ha aumentado por el cambio climático y el crecimiento de la actividad humana en zonas boscosas (here). Estos eventos pueden partir de un origen natural o antrópico (provocados, por ejemplo, por negligencia humana) y generan consecuencias graves como daños en infraestructuras, pérdida de biodiversidad y efectos económicos significativos.

La creciente frecuencia de incendios en bosques y otros biomas ha impulsado el desarrollo de sistemas automáticos de vigilancia diseñados para detectar fuego y humo de manera temprana, reduciendo el tiempo de respuesta de los equipos de extinción y minimizando la propagación de los incendios.

El aprendizaje profundo (*deep learning*) ha demostrado ser altamente eficaz en el análisis de imágenes, especialmente para la detección de incendios y humo, superando limitaciones presentes en métodos tradicionales. En este trabajo, se desarrollará un modelo basado en estas tecnologías para...

## 2 Planteamiento del Problema

### 3 Estado del Arte

## 4 Marco Teórico

El propósito de este marco teórico es introducir los conceptos clave que permitan abordar la problemática de la detección de incendios forestales a partir del análisis de imágenes con técnicas de aprendizaje profundo. Se explorarán las capacidades de las redes neuronales, específicamente las redes neuronales convolucionales (CNNs), como herramientas a usar para la detección y mitigación de estos eventos.

### 4.1 Redes Neuronales Convolucionales

Las redes neuronales convolucionales (CNNs) son un tipo de arquitectura de aprendizaje profundo altamente efectiva para el procesamiento de datos que se pueden representar como una cuadrícula, como lo son las imágenes. Su diseño les permite aprender de forma automática jerarquías espaciales y patrones relevantes, lo cual las convierte en una herramienta ideal para la clasificación de imágenes y la detección de objetos.

Su arquitectura generalmente consta de tres tipos de capas principales: convolucionales, de agrupación (*pooling*) y completamente conectadas. Las capas convolucionales aplican filtros a la imagen de entrada para extraer características relevantes, mientras que las de agrupación reducen la dimensionalidad de las características extraídas. Finalmente, las capas completamente conectadas se encargan de la clasificación final, al asegurar que cada neurona de salida esté conectada a todas las neuronas de la capa anterior.

El uso de CNNs en la detección de humo de incendios forestales se ha vuelto clave gracias a su capacidad para procesar grandes volúmenes de datos visuales, como imágenes satelitales y transmisiones de cámaras de vigilancia. Esto permite diferenciar el humo de elementos como nubes o niebla, y de forma más eficiente a diferencia de métodos tradicionales.

### 4.2 YOLO

You Only Look Once es un modelo avanzado de detección de objetos diseñado para identificar y localizar elementos en imágenes en tiempo real con alta precisión. Su funcionamiento se basa en redes neuronales convolucionales (CNNs) para analizar imágenes con un solo procesamiento, dividiéndolas en cuadrículas y prediciendo la posición, dimensiones y clase de los objetos detectados.

YOLOv8, la versión más reciente, introduce un enfoque sin anclas (*anchor-free*), eliminando las posiciones predefinidas de las cajas delimitadoras usadas en versiones anteriores. Esto le ayuda a simplificar el entrenamiento y mejorar la precisión en la detección de objetos con formas y tamaños variables. Además, incorpora CSPNet (*Cross-Stage Partial Networks*) como backbone, una arquitectura que optimiza el flujo de información y reutiliza características de capas anteriores para reducir las redundancias y mejorar la eficiencia computacional.

Estas características le permiten a YOLOv8 servir como herramienta altamente eficaz para tareas en tiempo real, y para actividades de vigilancia y monitoreo ambiental como es el caso de la detección de incendios forestales.

### 4.3 Transfer Learning

El aprendizaje por transferencia es una técnica de aprendizaje automático que consiste en reutilizar conocimientos aprendidos en un dominio para mejorar el rendimiento en otro dominio relacionado. En el contexto de las redes neuronales, esto implica tomar una red preentrenada en un conjunto de datos grande y ajustarla a un conjunto de datos más pequeño y específico.